

Instituto Tecnológico de Buenos Aires

Procesamiento de Señales e Imágenes Biomédicas (16.63)

Comisión BIO

Anteproyecto

Segmentación y clasificación de lesiones mamarias en ecografía

Grupo 2

65555 – Cassano Nieto, Facundo Tomás (fcassanonieto@itba.edu.ar)

65414 – D'Elía, Lucas Valentín (ldelia@itba.edu.ar)

65560 – Ortega, Facundo (facortega@itba.edu.ar)

Docentes

Tomás, Roberto Sebastián

Capurro, Lucila

Reppucci, Victoria

Tassara, Francisco Joaquín

10 de octubre de 2026

1. Introducción

1.1. Problemática

La ecografía en modo B es el estudio de primera línea para caracterizar nódulos mamarios palpables y para estudiar pacientes con mamas densas. El radiólogo describe cada lesión con el léxico BI-RADS (*Breast Imaging Reporting and Data System*) del American College of Radiology [1], que considera su forma, orientación, margen, ecogenicidad y rasgos acústicos posteriores, y la asigna a una categoría. La categoría 3 corresponde a una probabilidad de malignidad de hasta 2 % y se indica seguimiento; las categorías 4 y 5 llevan a biopsia.

Hoy esta evaluación es visual y depende de quién haga el estudio. Sin embargo, los criterios ecográficos de malignidad descritos por Stavros et al. [2] son en su mayoría geométricos o de textura: forma irregular, orientación "más alta que ancha" (el eje perpendicular a la piel mayor que el paralelo), márgenes angulares o espiculados, sombra acústica posterior y ecotextura heterogénea. Cada uno puede traducirse en una magnitud que se mide sobre la imagen una vez segmentada la lesión.

1.2. Marco teórico

Ruido speckle. La ecografía presenta un ruido multiplicativo de aspecto granular, el speckle, producido por la interferencia de las ondas que reflejan muchos dispersores pequeños. Como multiplica a la imagen en lugar de sumarse, los filtros pensados para ruido aditivo no son los más adecuados, y como cambia la textura de la imagen, puede confundirse con la textura del tejido. Cuando está completamente desarrollado, es decir, cuando cada punto de la imagen recibe ecos de muchos dispersores, su amplitud sigue una distribución de Rayleigh. En ese caso, el cociente entre media y desvío de una zona homogénea vale 1,91 sin importar su brillo [3]. Usaremos este valor como referencia para comprobar si el speckle de las imágenes se comporta como supone el modelo. También permite medir cuánto speckle quita un filtro, ya que el cociente aumenta a medida que la zona queda más uniforme.

Bordes débiles. Las lesiones suelen ser hipoecoicas (más oscuras que el tejido vecino), pero sus bordes son difusos y pueden quedar parcialmente ocultos por sombras acústicas. Los detectores de bordes vistos en clase (Sobel, Canny) responden también al speckle. El método de Chan-Vese [4], también visto en clase, funciona aunque el borde no sea marcado, siempre que el interior y el exterior sean distintos, pero supone que cada región tiene una única intensidad media en toda la imagen.

Textura. La matriz de co-ocurrencia de niveles de gris (GLCM) describe con qué frecuencia aparecen juntos pares de niveles de gris a una distancia y dirección dadas, y de ella se calculan los rasgos de Haralick [5, 6]. Sus valores dependen del nivel de gris absoluto, que varía con la ganancia configurada en cada ecógrafo.

1.3. Estado del arte

Los primeros sistemas de diagnóstico asistido siguen los mismos pasos que el radiólogo. Delimitan la lesión, miden propiedades parecidas a las del léxico BI-RADS y se las entregan a un clasificador, que le asigna a cada lesión una probabilidad de malignidad. Según el umbral a partir del cual se la considera maligna cambian la sensibilidad (fracción de malignas detectadas) y la especificidad (fracción de benignas reconocidas como tales). La curva ROC muestra ese compromiso para todos los umbrales, y el área bajo ella (AUC) vale 1 si el clasificador separa perfectamente ambas clases y 0,5 si no es mejor que el azar. Con este enfoque, Chen et al. [7] obtienen un AUC de 0,95 en 271 lesiones con siete descriptores morfológicos, y Byra et al. [8] de 0,90 en 107 lesiones usando solo morfología. Es decir, la forma de la lesión ya alcanza para separar bien benignas y malignas.

Los trabajos más recientes usan redes neuronales convolucionales que reciben la imagen completa y aprenden solas qué patrones usar. Byra et al. [9], por ejemplo, obtienen un AUC de 0,89 con 882 imágenes, un valor similar al de los descriptores morfológicos, pero la red no permite saber en qué se basa cada decisión. Además, muchos de estos trabajos se evalúan sobre BUSI, la base pública más

usada, que tiene alrededor de un 19 % de imágenes duplicadas, algunas con etiquetas contradictorias [10]. Si una misma imagen queda en entrenamiento y en prueba, el resultado es optimista.

Por eso seguimos el primer enfoque, que permite explicar cada decisión a partir de propiedades medibles de la imagen. Como los valores de AUC citados provienen de bases chicas y de un solo equipo, no buscamos superarlos, y en cambio medimos cuánto aporta cada técnica. A las vistas en clase sumamos tres que no se vieron, una por cada dificultad descrita en el marco teórico. Para el speckle usamos la difusión anisótropa para reducción de speckle (SRAD) [11], que lo suaviza sin borrar los bordes. Para los bordes débiles usamos contornos activos con estadísticos locales [12], que segmentan aunque la intensidad del fondo no sea uniforme. Para la textura usamos patrones binarios locales (LBP) [13], que no dependen de la ganancia del equipo.

1.4. Objetivos e hipótesis

Objetivo general. Desarrollar un algoritmo que segmente la lesión en una ecografía mamaria, mida descriptores de forma, intensidad y textura y estime si es benigna o maligna, con decisiones explicables a partir de la imagen; cuantificar cuánto mejora cada técnica incorporada a su equivalente visto en clase, y desarrollar una interfaz gráfica que muestre cada etapa del procesamiento.

Hipótesis. H1, reducir el speckle con SRAD mejora la segmentación respecto de los filtros de mediana y de Wiener; **H2**, los contornos activos con estadísticos locales segmentan mejor que Chan-Vese, sobre todo en lesiones con sombra acústica posterior; **H3**, agregar descriptores LBP a los de GLCM mejora la clasificación entre benignas y malignas; **H4**, el desempeño del algoritmo se mantiene con niveles moderados de compresión JPEG.

2. Materiales y métodos

2.1. Base de datos

Usaremos la base **BrEaST** (*Breast-Lesions-USG*) [14, 15], publicada en The Cancer Imaging Archive: 256 ecografías, una por paciente, de mujeres de 18 a 87 años atendidas en Polonia entre 2019 y 2022, adquiridas con ecógrafos Hitachi, Esaote, Samsung y Philips con transductores lineales, en formato PNG en escala de grises y con licencia CC BY 4.0. Contiene 154 lesiones benignas, 98 malignas y 4 imágenes sin lesión. Cada lesión tiene diagnóstico confirmado por biopsia (77 %) o por un seguimiento mayor a 2 años, máscara dibujada a mano por radiólogos, descriptores BI-RADS (categoría, forma, margen, ecogenicidad y rasgos posteriores) y el tamaño del píxel. La elegimos por la calidad de su anotación y porque, a diferencia de BUSI, no tiene imágenes duplicadas.

La unidad de análisis es la lesión principal de cada una de las 252 imágenes con lesión; las 4 imágenes sin lesión se usan para verificar que el algoritmo no proponga una lesión inexistente. Las imágenes se separan en entrenamiento (70 %) y prueba (30 %), manteniendo la proporción de benignas y malignas. Como hay una sola imagen por paciente, ninguna paciente aparece en ambos conjuntos. Todo lo que se ajusta con datos (parámetros de los filtros y de la segmentación, selección de descriptores y clasificador) se ajusta solo con el conjunto de entrenamiento, mediante validación cruzada, y el de prueba se usa una única vez, al final. Si se lo usara para ajustar, el resultado sería optimista. El algoritmo final queda con parámetros fijos, para poder aplicarlo a los casos incógnita de la cátedra.

2.2. Metodología

Las etapas 1 a 4 preparan la imagen, la 5 y la 6 segmentan la lesión, la 7 calcula sus descriptores y la 8 la clasifica.

1. **Análisis exploratorio.** Se relevan los tamaños de las imágenes, el tamaño del píxel y la presencia de marcas sobreimpresas (calibres de medición, texto). Se calculan los histogramas de la lesión y del tejido vecino, y el cociente entre media y desvío en regiones homogéneas: si se acerca a 1,91, el speckle está completamente desarrollado; si se aleja, probablemente se deba a que el ecógrafo ya comprimió y procesó la imagen antes de exportarla. En ese caso SRAD sigue siendo aplicable,

porque estima el speckle de referencia en la propia imagen. Define los criterios de limpieza y los valores iniciales de los parámetros de las etapas siguientes.

2. **Preprocesamiento.** Se normaliza la intensidad entre 0 y 1. Las marcas sobreimpresas se detectan por su intensidad o color y se rellenan interpolando los píxeles vecinos; si una marca cae sobre la lesión, la imagen se excluye. Luego se recorta una región de interés (ROI) alrededor de la lesión, con un margen de tejido vecino, que hace falta para medir la ecogenicidad relativa y los rasgos posteriores. La ROI se propone de forma automática: sobre la imagen suavizada se aplica el umbral de Otsu [16], se etiquetan las regiones oscuras conexas y se elige la más probable según su intensidad media, su cercanía al centro horizontal, su área y que no toque los bordes de la imagen. En la interfaz el usuario puede corregirla, como haría un radiólogo al ubicar los calibres.

3. **Compresión y descompresión.** Las imágenes clínicas se almacenan y transmiten comprimidas (sistemas de archivo de imágenes, telemedicina). Para medir cuánto afecta eso al algoritmo, cada imagen se comprime con JPEG a distintos niveles de calidad y se descomprime. La distorsión se mide con la relación señal a ruido de pico (PSNR), que compara el máximo nivel de gris con el error cuadrático medio entre la imagen original y la descomprimida, y con el índice de similitud estructural (SSIM) [17], que compara luminancia, contraste y estructura local y se parece más a cómo percibimos la calidad. Todo el algoritmo se repite sobre las versiones comprimidas (H4).

4. **Reducción de speckle con SRAD.** En clase se vieron el filtro de mediana y el de Wiener. La versión local de Wiener, el filtro de Lee [18], calcula la media y la varianza de una ventana alrededor de cada píxel: si esa varianza se explica por el speckle, la zona es homogénea y el píxel se reemplaza por la media; si es mucho mayor, hay un borde y el píxel se conserva. El problema es que la ventana es fija y cuadrada, y cerca de un borde mezcla píxeles de ambos lados. SRAD [11] usa el mismo criterio, pero suaviza la imagen de forma iterativa: en cada paso, cada píxel intercambia intensidad con sus vecinos en una cantidad que depende de cuánto se parece su variación local, calculada a partir del gradiente y el laplaciano, a la del speckle, estimada en una región homogénea. Donde la variación se explica por el speckle la imagen se suaviza, y donde es mucho mayor hay un borde y el suavizado se detiene. Así el suavizado sigue la forma de los bordes en lugar de una ventana fija. Se implementa con diferencias finitas, con un paso temporal de a lo sumo 1/4 para que la iteración no diverja, y luego se ecualiza el histograma para mejorar el contraste. Para elegir el filtro se miden el cociente entre media y desvío en regiones homogéneas (cuanto mayor, menos speckle queda), el contraste entre lesión y fondo y, como criterio final, la calidad de la segmentación que resulta de cada uno.

5. **Segmentación con contornos activos locales.** Como referencia se aplican los métodos vistos en clase: el umbral de Otsu, que elige el nivel de gris que mejor separa dos clases y toma la oscura como lesión; el crecimiento de regiones desde una semilla en el centro de la ROI; k-means y Chan-Vese. Chan-Vese busca el contorno que hace que los píxeles de adentro se parezcan lo más posible a su media, y los de afuera a la suya, penalizando además los contornos largos e irregulares. Esto supone que cada región tiene una única intensidad media, lo que en ecografía no se cumple: la intensidad del tejido cae con la profundidad y las sombras acústicas oscurecen zonas que no son lesión, de modo que una media global de "afuera" no representa al tejido que rodea cada parte del borde. Los contornos activos con estadísticos locales [12] mantienen la misma idea, pero comparan cada punto del contorno solo con un disco de radio r a su alrededor, calculando las medias de adentro y de afuera dentro de ese disco. Si el disco abarca toda la imagen se recupera Chan-Vese; con un radio menor, alcanza con que la lesión sea más oscura que el tejido inmediatamente vecino, lo que sí se cumple aunque el fondo varíe. El contorno parte del resultado de Otsu y evoluciona hasta minimizar esa energía; el radio y el peso de la longitud se ajustan con el conjunto de entrenamiento.

6. **Morfología y etiquetado.** Una apertura con un elemento estructurante en forma de disco elimina las islas pequeñas debidas al speckle, y un cierre une los huecos del borde; luego se rellenan los agujeros interiores. Se etiquetan las regiones conexas y se conserva la que contiene

Tabla 1: *Correspondencia con los contenidos de la consigna.*

Ítem de la consigna	Implementación	Etapa
Contextualización de las imágenes y la base	Ecografía modo B, speckle, equipos, diagnóstico de referencia	Sec. 2.1, 1
Mejoramiento de imágenes	Mediana, Wiener y SRAD; ecualización de histograma	4
Compresión y descompresión	JPEG a distintas calidades; PSNR y SSIM	3
Segmentación de imágenes	Otsu, crecimiento de regiones, k-means, Chan-Vese y contornos activos locales; morfología y etiquetado	2, 5, 6
Análisis de texturas	GLCM y rasgos de Haralick; LBP	7
Resultados y significancia estadística	Contornos superpuestos, métricas de segmentación y clasificación, pruebas estadísticas	Sec. 3
Interfaz gráfica	Aplicación en Streamlit	9
Técnicas no vistas en clase	SRAD, contornos activos locales, LBP	4, 5, 7

la semilla. El resultado es la máscara final de la lesión y su caja contenedora.

7. **Descriptores de forma, intensidad y textura.** Los de *forma* siguen el léxico BI-RADS: la circularidad $4\pi A/P^2$ (A es el área y P el perímetro; vale 1 en un círculo) y la solidez (área de la lesión sobre la de su envolvente convexa, que baja con las concavidades) describen si es oval o irregular; el cociente entre el alto y el ancho de la caja contenedora mide la orientación (mayor a 1 es "más alta que ancha"); el desvío de la distancia de cada punto del contorno al centroide, normalizado por la distancia máxima, crece con márgenes angulares o espiculados; y el eje mayor en milímetros da el tamaño. Los de *intensidad* son la ecogenicidad relativa (media de la lesión sobre la de un anillo de tejido vecino) y el índice acústico posterior (media de la región debajo de la lesión sobre la de las regiones laterales a la misma profundidad: menor a 1 indica sombra y mayor a 1, refuerzo). Para la *textura* se calcula la GLCM dentro de la lesión, promediada en las cuatro direcciones para que no dependa de la orientación, y de ella los rasgos de Haralick [5]: energía, entropía, contraste, homogeneidad, correlación, *cluster shade* y *cluster prominence*. Como la GLCM depende del nivel de gris absoluto, se agrega LBP [13]: cada píxel se compara con 8 vecinos ubicados sobre un círculo, cada vecino mayor o igual al centro aporta un 1 y cada vecino menor un 0, y el código binario resultante describe el patrón local (borde, esquina, zona plana). Como solo usa el signo de las diferencias, no cambia con la ganancia ni el brillo; con la versión invariante a la rotación quedan 10 códigos posibles, y el descriptor es el histograma de códigos dentro de la lesión, calculado para dos radios. La GLCM mide qué niveles de gris aparecen juntos y LBP qué patrones locales aparecen, por lo que son complementarios. Los descriptores se estandarizan con la media y el desvío del conjunto de entrenamiento. Como hay unas 69 lesiones malignas en entrenamiento y se recomiendan unos 10 casos de la clase menos frecuente por descriptor, se seleccionan unos 7, dentro de la validación cruzada.

8. **Clasificación.** Usaremos análisis discriminante lineal (LDA), que supone que los descriptores de cada clase siguen una distribución gaussiana con la misma covarianza. Con esa suposición, la regla que asigna cada lesión a la clase más probable es lineal, y el peso de cada descriptor en la decisión se puede leer directamente. Su salida es la probabilidad de malignidad de cada lesión.

9. **Interfaz gráfica.** Aplicación en Streamlit para cargar una imagen, ver y corregir la ROI propuesta, ver el resultado de cada etapa (original, filtrada, máscara y contorno superpuesto) y consultar los descriptores y la probabilidad de malignidad.

3. Evaluación

Todo se mide sobre las imágenes de prueba. La segmentación se compara con la máscara del radiólogo mediante el coeficiente de Dice, que vale 1 si las máscaras coinciden y 0 si no se superponen, y la distancia de Hausdorff, que mide cuánto se aleja el peor tramo del contorno; se usa su percentil 95 para que no la domine un único píxel aislado. La clasificación se mide con el AUC, que indica qué

tan bien se ordenan las lesiones malignas por encima de las benignas sin depender de un umbral, con un intervalo de confianza del 95 % obtenido por remuestreo (*bootstrap*). Se reportan además la sensibilidad y la especificidad en dos umbrales: el que maximiza su suma y el que asegura una sensibilidad de al menos 98 %. Este último se relaciona con la categoría BI-RADS 3, que admite hasta un 2 % de malignidad, e indica cuántas biopsias de lesiones benignas podrían evitarse sin dejar de detectar cánceres.

Para verificar las hipótesis: **H1**, se compara el Dice obtenido sin filtrar y con mediana, Wiener y SRAD, manteniendo fijo el método de segmentación; **H2**, se compara el Dice de los contornos activos locales con el de Chan-Vese y los demás métodos de clase, en todas las lesiones y por separado en las que tienen sombra acústica posterior según la anotación de la base; **H3**, se compara el AUC con descriptores GLCM solos y con GLCM y LBP, por remuestreo pareado sobre las mismas lesiones; **H4**, se grafican PSNR, SSIM, Dice y AUC en función de la calidad JPEG. Las comparaciones de Dice se hacen imagen por imagen con la prueba de Wilcoxon, que no supone distribución normal. Por último, para verificar que los descriptores miden lo que dicen medir, se compara cada descriptor de forma entre las categorías BI-RADS anotadas por los radiólogos (por ejemplo, la solidez entre lesiones ovales e irregulares) con la prueba U de Mann-Whitney.

Bibliografía

[1] American College of Radiology, *ACR BI-RADS Atlas*, 5.ª ed. ACR, 2013.

[2] A. T. Stavros et al., "Solid breast nodules: use of sonography to distinguish between benign and malignant lesions," *Radiology*, 196(1):123–134, 1995.

[3] R. F. Wagner et al., "Statistics of speckle in ultrasound B-scans," *IEEE Trans. Sonics Ultrason.*, 30(3):156–163, 1983.

[4] T. F. Chan, L. A. Vese, "Active contours without edges," *IEEE Trans. Image Process.*, 10(2):266–277, 2001.

[5] R. M. Haralick, K. Shanmugam, I. Dinstein, "Textural features for image classification," *IEEE Trans. Syst. Man Cybern.*, 3(6):610–621, 1973.

[6] R. C. Gonzalez, R. E. Woods, *Digital Image Processing*, 4.ª ed. Pearson, 2018.

[7] C. M. Chen et al., "Breast lesions on sonograms: computer-aided diagnosis with nearly setting-independent features and artificial neural networks," *Radiology*, 226(2):504–514, 2003.

[8] M. Byra et al., "Added value of morphological features to breast lesion diagnosis in ultrasound," arXiv:1706.01855, 2017.

[9] M. Byra et al., "Breast mass classification in sonography with transfer learning using a deep convolutional neural network and color conversion," *Med. Phys.*, 46(2):746–755, 2019.

[10] A. Pawłowska, P. Karwat, N. Żołek, "Letter to the Editor. Re: 'Dataset of breast ultrasound images'," *Data Brief*, 2023.

[11] Y. Yu, S. T. Acton, "Speckle reducing anisotropic diffusion," *IEEE Trans. Image Process.*, 11(11):1260–1270, 2002.

[12] S. Lankton, A. Tannenbaum, "Localizing region-based active contours," *IEEE Trans. Image Process.*, 17(11):2029–2039, 2008.

[13] T. Ojala, M. Pietikäinen, T. Mäenpää, "Multiresolution gray-scale and rotation invariant texture classification with local binary patterns," *IEEE Trans. Pattern Anal. Mach. Intell.*, 24(7):971–987, 2002.

[14] "Breast-Lesions-USG (BrEaST)," The Cancer Imaging Archive, doi:10.7937/9WKK-Q141.

[15] A. Pawłowska et al., "Curated benchmark dataset for ultrasound based breast lesion analysis," *Sci. Data*, 11:148, 2024.

[16] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Trans. Syst. Man Cybern.*, 9(1):62–66, 1979.

[17] Z. Wang, A. C. Bovik, H. R. Sheikh, E. P. Simoncelli, "Image quality assessment: from error visibility to structural similarity," *IEEE Trans. Image Process.*, 13(4):600–612, 2004.

[18] J. S. Lee, "Digital image enhancement and noise filtering by use of local statistics," *IEEE Trans. Pattern Anal. Mach. Intell.*, 2(2):165–168, 1980.